

Graph Neural Network for Fraud Detection via Spatial-temporal Attention

作者: Dawei Cheng, Xiaoyang Wang, Ying Zhang and Liqing Zhang

Department of Computer Science and Engineering, Shanghai Jiao Tong University

IEEE TKDE 2015

Abstract

提出了一种基于时空注意的图网络 (STAGN), 用于信用卡欺诈检测。

我们首先通过图神经网络学习基于时间和位置的事务图特征。然后使用时空注意力网络, 然后将其馈入3D卷积网络。注意力权重是通过3D卷积和检测网络以端到端的方式共同学习的。

实验结果表明, STAGN在AUC和精确召回曲线上的表现均优于其他最新基准。还证明了该方法在其他基于用户行为的任务中的有效性。最后, 为了应对大数据的挑战STAGN作为预测模型集成到欺诈检测系统中, 并提出了系统中每个模块的实现细节。

创新点/贡献/优势:

- 使用时空注意力机制、3-D卷积
- 一个统一的时空注意力框架
- 在实验结果中达到了最好的效果
- 可以预测每秒10000的交易, 达到行业标准

Introduction

- 对于信用卡欺骗检测一般使用两种方法
 - 基于规则: 由先到知识生产复杂的规则去进行判断 (频繁欺诈模式)
 - 基于机器学习: 提取特征, 有监督学习分类 (无法学习到时空特征)
- 对于信用卡问题存在时空的高度聚集性

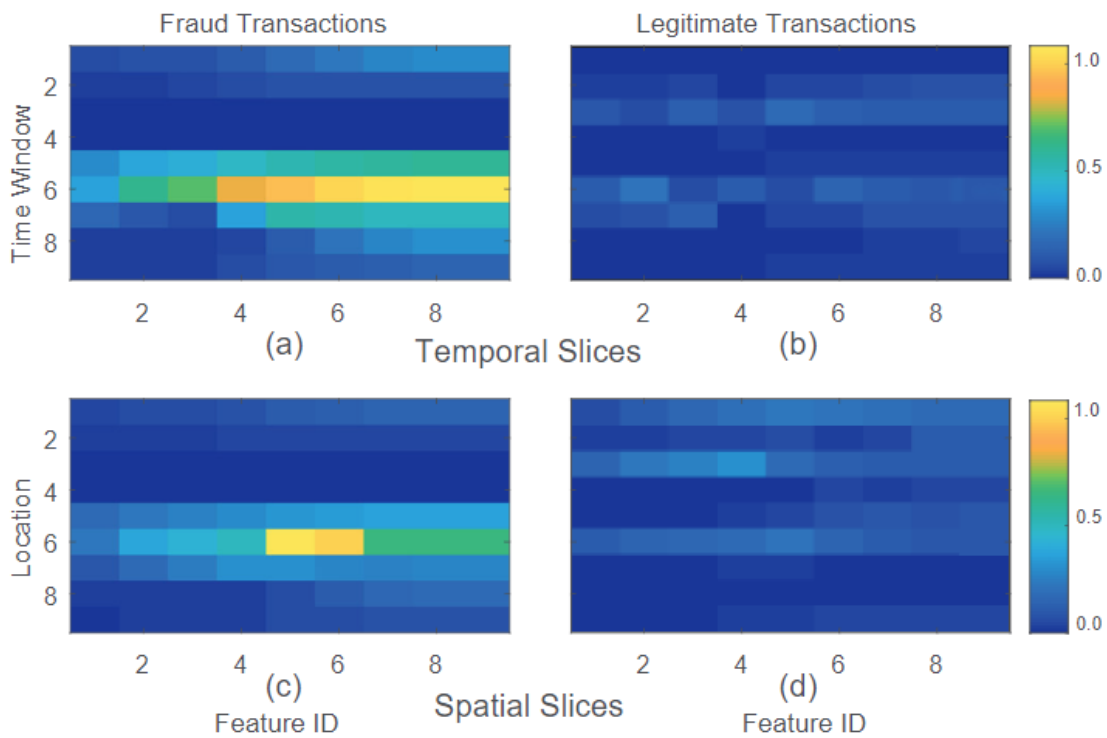


Fig. 2. Heat maps of spatial-temporal feature slices from both fraudulent and legitimate transactions.

- 引用的CV的技术：将Attention使用在时空的信息上（对于视频像素容易使用注意力机制），要使用在交易图上面具有挑战性
- 3-D卷积在时空特征提取上具有优势

Model

$r = \{u, t, l, m, a\}$, u 是用户, t 是时间, l 是位置编号, m 是收款人/机器编号, a 是付款数量


时间切片：不同时间窗口的特征

空间切片，不同空间位置的特征

问题描述：给定一组交易记录 $R = \{U, T, L, M, A\}$ ，一组欺诈事件 D ，以及时间窗口 $t_i \& t_i + 1$ ，用于 $(t_i, t_i + 1]$ 我们要根据从 t_1 到 t_i 的记录推断是否为欺诈事件，目的是实现高精度的欺诈预测，并探索信用卡交易的欺诈模式

一个 r 对应一个3-D矩阵，表示了交易特征和基于位置图的特征

v_e 是边信息（交易数、位置）， v_g 全局的图特征， v_u, v_m 是随机的特征向量， v_v 是 v_u, v_m 的结合



根据时间的变化，边的出现，绿色为发送者，橘色为接收者

Location-based Graph Neural Network

$$v'_{eik} = \text{NN}_e(v_{eik}, I_{ui}, I_{mk}, v_g)$$

更新边的特征

$$v'_{ui} = \text{NN}_v \left(\sum_{k=1}^{N_m} (v'_{eik}), v_{ui}, v_g \right)$$

$$v'_{mk} = \text{NN}_v \left(\sum_{i=1}^{N_u} (v'_{eik}), v_{mk}, v_g \right)$$


更新点的特征

$$v'_g = \text{NN}_g(\bar{v}_u, \bar{v}_m, \bar{v}_e, v_g) \quad (3)$$


where

$$\bar{v}_u = \frac{1}{N_u} \sum_i^{N_u} v'_{ui}, \quad \bar{v}_m = \frac{1}{N_m} \sum_k^{N_m} v'_{mk} \quad (4)$$


更新全局图的特征




(a) Edge Update



(b) Node Update



(c) Global Update



(d) Full GNN Layer

Spatial-temporal Attention Net

对于时间切片

$$rept = \sum_{\bar{t}=1}^{N_1} a_{1,\bar{t}} \mathcal{X}(\bar{t}, :, :) \quad (5)$$

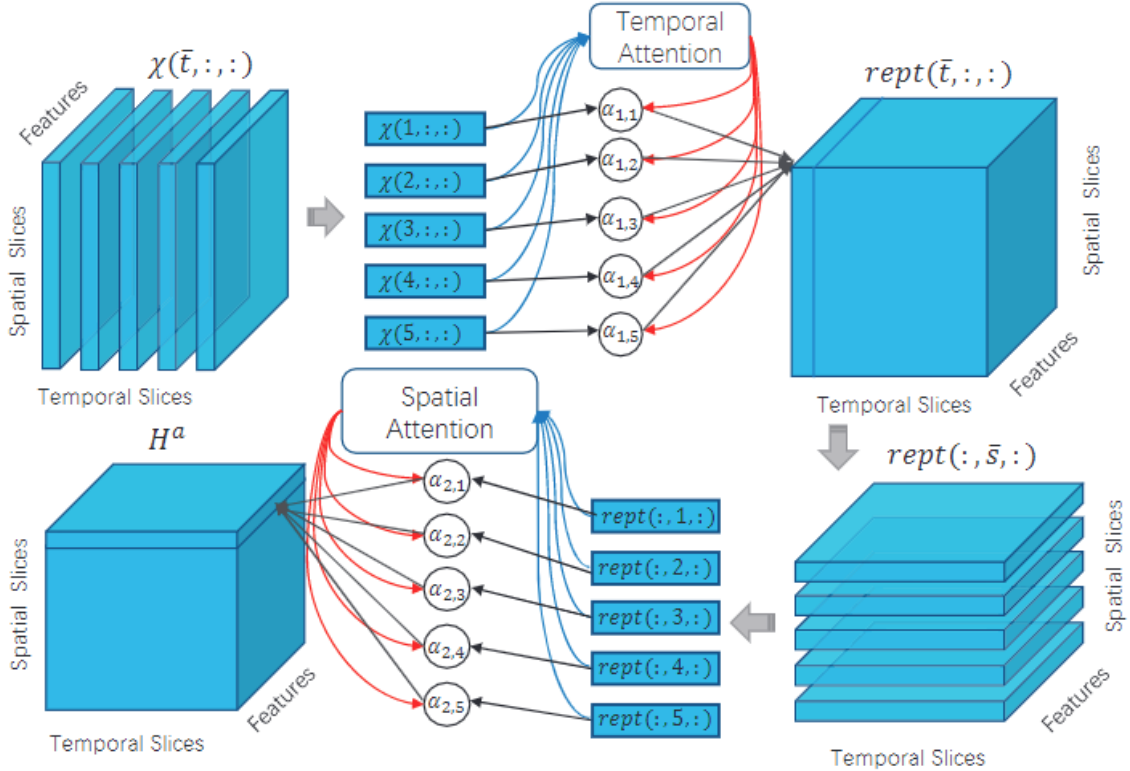
$$a_{1,\bar{t}} = \frac{\exp((1 - \lambda_1) \cdot \text{NN}_{\bar{t}}(W_{\bar{t}}, \mathcal{X}(\bar{t}, :, :)))}{\sum_{\bar{t}=1}^{N_1} \exp((1 - \lambda_1) \cdot \text{NN}_{\bar{t}}(W_{\bar{t}}, \mathcal{X}(\bar{t}, :, :)))} \quad (6)$$

对于空间切片

$$\mathcal{H}^a = \sum_{\bar{s}=1}^{N_2} a_{2,\bar{s}} rept(:, \bar{s}, :) \quad (7)$$

$$a_{2,\bar{s}} = \frac{\exp((1 - \lambda_2) \cdot \text{NN}_{\bar{s}}(W_{\bar{s}}, rept(:, \bar{s}, :)))}{\sum_{\bar{s}=1}^{N_2} \exp((1 - \lambda_2) \cdot \text{NN}_{\bar{s}}(W_{\bar{s}}, rept(:, \bar{s}, :)))} \quad (8)$$

使用注意力机制, \mathcal{X} 是3维特征矩阵, 对于每一个交易记录

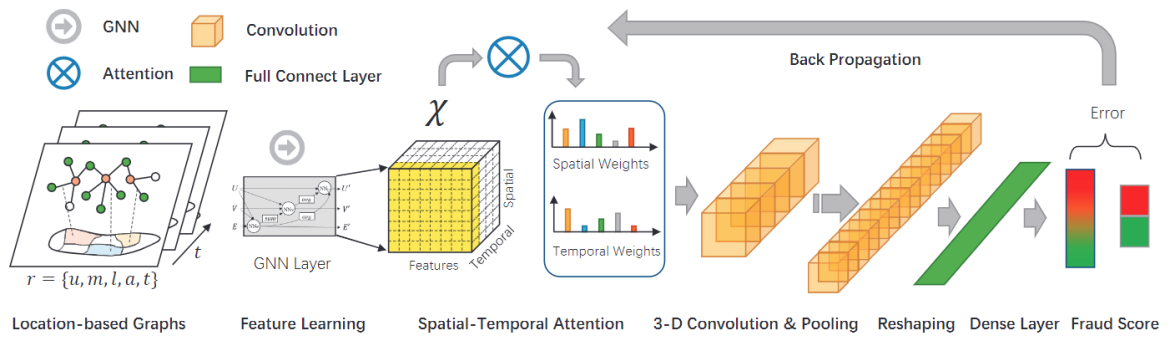


使用时间注意力机制, 更新时间切片, 在此基础上在使用空间注意力机制

3D Convolutional Layers

$$\mathcal{H}_j^c = \sum_j \mathcal{H}^{c-1}(c_t - c_m, c_s - c_n, c_f - c_o) \mathcal{W}_i^c(c_m, c_n, c_o) \quad (9)$$

W 是要训练的权重



Experiments

数据集

从一家大型商业银行收集了欺诈交易，其中包括2016年1月1日至12月31日的十二个月的真实信用卡交易记录（3个 σ 的规则删除离群点）

数据集包含1021个用户 1160个位置编码 236706笔交易记录。

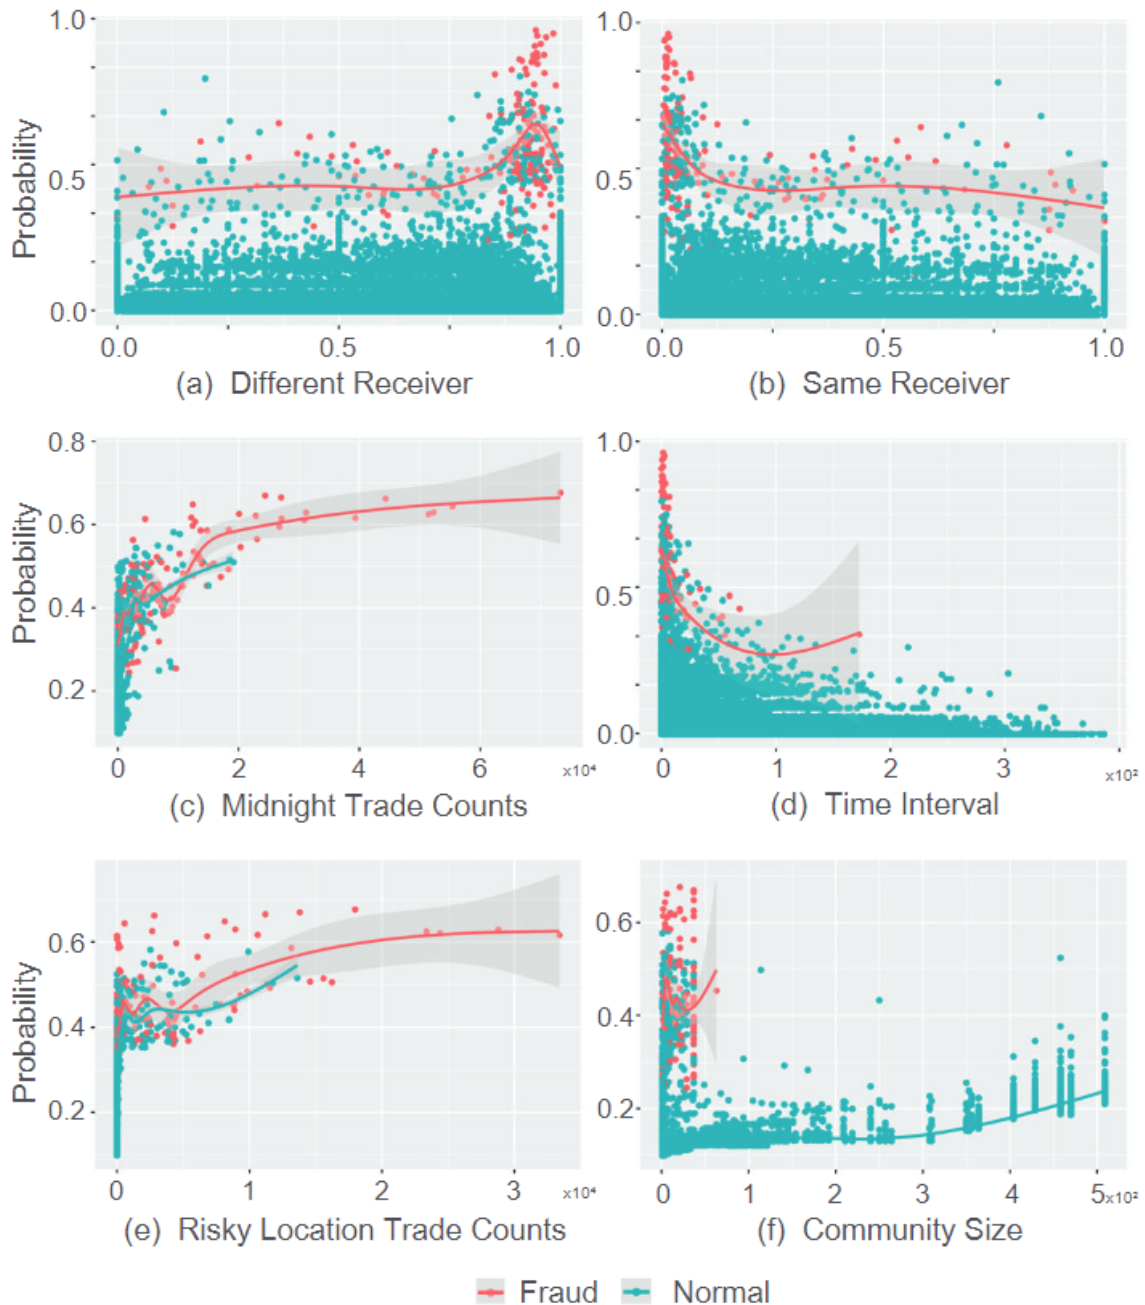
TABLE 1
Result of the fraud detection experiment.

	AUC (Oct)	AUC (Nov)	AUC (Dec)
LR	0.7247	0.7163	0.7199
GBDT	0.7868	0.7949	0.7864
MLP	0.7803	0.8012	0.7891
Deep & Wide	0.8210	0.8197	0.8108
CNN-max	0.8352	0.8367	0.8267
AdaBM	0.8243	0.8249	0.8232
LSTM-seq	0.8368	0.8353	0.8290
STAGN-nograph	0.8435	0.8462	0.8509
STAGN-notrans	0.8413	0.8507	0.8596
STAN	0.8832	0.8789	0.8865
STAGN-notemp	0.8631	0.8604	0.8736
STAGN-nospat	0.8602	0.8531	0.8583
STAGN-no3d	0.8688	0.8629	0.8716
STAGN-all	0.8973**	0.8897**	0.8983**

TABLE 2
The value of attention coefficients.

Temporal	Coefficients	Spatial	Coefficients
Seconds	0.2137	#13	0.1447
Minutes	0.0615	#21	0.1001
Hours	0.1533	#36	0.0158
Days	0.1057	#39	0.0192
Weeks	0.2930	#42	0.0374
Months	0.0104	#47	0.0182
Quarters	0.0006	#48	0.0091

对于时间的不同权重



通过实验，证明了先前的假设欺诈者具有高度的时空聚集性

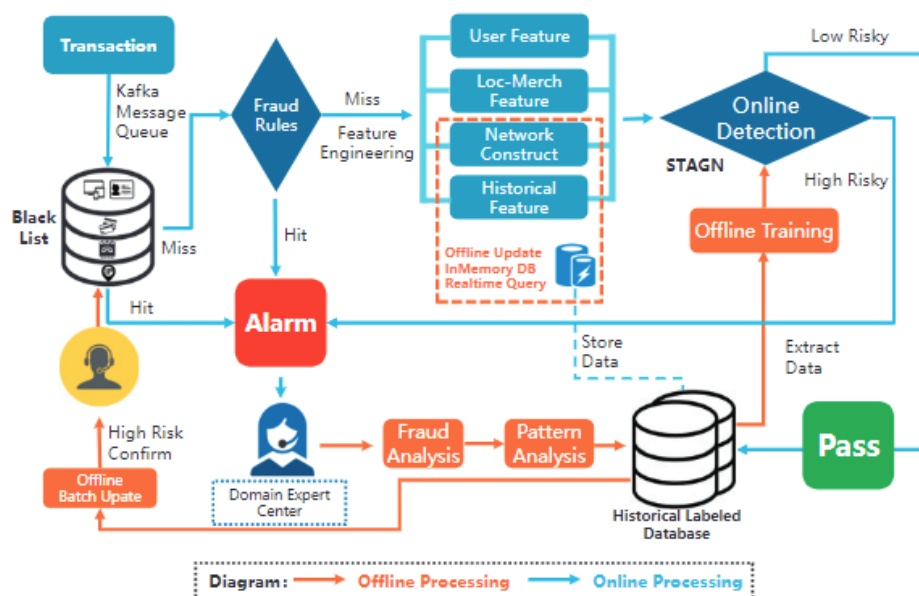


Fig. 13. The implementation of our proposed methods in an online and realtime fraud detection system.

设计插件，投入商业使用，设计模型

Conclusion

本文提出了一种用于信用卡欺诈检测的新型注意力3D卷积神经网络。

发现欺诈者的“时间聚集”和“空间聚集”，并提出了一种基于时空注意机制的3D卷积神经网络方法。

结果结果发现该方法可以有效地检测欺诈交易。

此外，作者计划研究将在线电子商务行为整合到欺诈检测模型中，并构建一个实时的流程中欺诈检测系统。